

UNet Polyp Segmentation SaaS

MID-TERM

INTELIGENCIA ARTIFICIAL

1st Amber Nadyne Grijalba Vargas

Escuela de Ingeniería Biomédica

Universidad Latina de Panamá

Panamá, Panamá

ambervg4733@gmail.com

Abstract—Early detection of colorectal polyps plays a crucial role in the prevention of colorectal cancer, one of the leading causes of cancer-related mortality worldwide. However, the identification of polyps during endoscopic procedures highly depends on the experience of the medical specialist, which may lead to variability and missed detections. In recent years, Artificial Intelligence and Deep Learning techniques have shown promising results as support tools for medical image analysis.

This project presents the development of a Software as a Service (SaaS) web application for automatic polyp segmentation in endoscopic images using a UNet-based deep learning model. The proposed system integrates a trained convolutional neural network with a FastAPI backend, enabling users to upload medical images through a web interface and obtain segmentation masks in real time. User authentication and security mechanisms are implemented using JSON Web Tokens (JWT), simulating a professional SaaS environment.

In addition to the technical implementation, the project includes a financial feasibility analysis using Net Present Value (NPV), Internal Rate of Return (IRR), and Payback Period metrics, demonstrating the potential economic viability of the proposed solution as a commercial medical support tool. The results show that the system is capable of performing effective segmentation while maintaining a scalable and practical architecture suitable for academic and real-world applications.

Index Terms—Deep Learning, UNet, Segmentación de imágenes, SaaS, FastAPI, Inteligencia Artificial Biomédica.

I. INTRODUCCIÓN

La detección temprana de pólipos colorrectales es un factor determinante en la prevención del cáncer colorrectal, una de las enfermedades con mayor incidencia y mortalidad a nivel mundial. Los pólipos son lesiones que se desarrollan en la mucosa del colon y, si no son detectados a tiempo, pueden evolucionar hacia formas malignas. Actualmente, la colonoscopia es el método más utilizado para la identificación de estas lesiones; sin embargo, su efectividad depende en gran medida de la experiencia del especialista y de factores humanos como la fatiga o la variabilidad en la interpretación de las imágenes endoscópicas.

En este contexto, la incorporación de herramientas de Inteligencia Artificial (IA) en el análisis de imágenes médicas surge como una alternativa para apoyar el proceso diagnóstico.

En particular, las técnicas de Deep Learning han demostrado un alto desempeño en tareas de segmentación de imágenes, permitiendo identificar regiones de interés con mayor precisión y consistencia. La segmentación automática de pólipos mediante modelos de aprendizaje profundo puede contribuir a reducir errores de omisión y mejorar la calidad del diagnóstico clínico.

Este proyecto propone el desarrollo de una aplicación web basada en un modelo de segmentación UNet, orientada a la identificación automática de pólipos en imágenes endoscópicas. La solución se implementa bajo un enfoque de Software as a Service (SaaS), integrando el modelo de Inteligencia Artificial en un backend desarrollado con FastAPI y ofreciendo acceso a través de una interfaz web segura y fácil de utilizar. De esta manera, el sistema permite que los usuarios carguen imágenes médicas y obtengan, en tiempo real, la máscara de segmentación correspondiente.

La motivación principal de este trabajo radica en la necesidad de trasladar los modelos de Inteligencia Artificial desde entornos experimentales o académicos hacia aplicaciones prácticas y accesibles. Además de evaluar el desempeño técnico del modelo, el proyecto incorpora un análisis de viabilidad financiera mediante métricas como el Valor Actual Neto (VAN), la Tasa Interna de Retorno (TIR) y el periodo de recuperación de la inversión (Payback), con el fin de analizar el potencial del sistema como una solución comercializable en el ámbito de la salud.

El objetivo general de este proyecto es diseñar e implementar una aplicación web funcional que consuma un servicio de Inteligencia Artificial para la segmentación automática de pólipos, demostrando su viabilidad técnica, operativa y económica. Como objetivos específicos se incluyen la integración de un modelo UNet entrenado, el desarrollo de una arquitectura backend robusta, la implementación de mecanismos de autenticación de usuarios y la evaluación del sistema desde una perspectiva financiera.

El presente documento se organiza de la siguiente manera: en la Sección II se presenta el marco teórico que sustenta el uso de técnicas de Deep Learning y la arquitectura UNet; en la Sección III se describe la metodología empleada para

el entrenamiento del modelo y el procesamiento de datos; la Sección IV detalla la arquitectura e implementación del sistema web; en la Sección V se presentan los resultados obtenidos; la Sección VI expone el análisis financiero del proyecto; y finalmente, en la Sección VII se discuten las conclusiones y el trabajo futuro.

II. MARCO TEÓRICO

La Inteligencia Artificial (IA) ha adquirido un papel fundamental en el ámbito médico durante los últimos años, especialmente en áreas relacionadas con el análisis de datos e imágenes médicas. La creciente disponibilidad de datos clínicos digitales, junto con el aumento de la capacidad computacional, ha permitido el desarrollo de sistemas capaces de apoyar procesos de diagnóstico, monitoreo y toma de decisiones clínicas.

En el contexto médico, la IA no busca reemplazar al profesional de la salud, sino funcionar como una herramienta de apoyo, proporcionando información adicional que ayude a reducir errores humanos, aumentar la precisión diagnóstica y optimizar el tiempo de análisis. Aplicaciones como la detección temprana de enfermedades, el análisis de imágenes médicas y la predicción de riesgos clínicos son ejemplos claros del impacto positivo de estas tecnologías.

A. Segmentación de Imágenes Médicas

La segmentación de imágenes médicas es una técnica fundamental en el procesamiento de imágenes, cuyo objetivo es identificar y delimitar regiones de interés dentro de una imagen. En el área clínica, esta técnica se utiliza para aislar estructuras anatómicas, tejidos o lesiones específicas, facilitando su análisis y visualización.

En el caso de las imágenes endoscópicas, la segmentación permite separar automáticamente los pólipos del fondo, lo cual es especialmente útil debido a la complejidad visual de este tipo de imágenes. A diferencia de la clasificación, donde se asigna una etiqueta a una imagen completa, la segmentación proporciona una salida a nivel de píxel, ofreciendo información más detallada y precisa [1] [2].

Las técnicas tradicionales de segmentación presentan limitaciones frente a variaciones de iluminación, textura y forma, lo que ha impulsado el uso de modelos basados en Deep Learning para abordar este problema de manera más robusta.

B. Redes Neuronales Convolucionales (CNN)

Las Redes Neuronales Convolucionales (Convolutional Neural Networks, CNN) son un tipo de red neuronal diseñada específicamente para el procesamiento de datos con estructura espacial, como las imágenes. Estas redes utilizan capas convolucionales que permiten extraer características locales, tales como bordes, patrones y formas, las cuales son esenciales para la interpretación visual.

Una CNN típica está compuesta por capas convolucionales, funciones de activación y capas de reducción de dimensionalidad (pooling). A medida que la información avanza a través de la red, las características aprendidas pasan de ser simples a

más complejas, permitiendo una representación jerárquica de la imagen.

Gracias a esta capacidad, las CNN se han convertido en la base de muchos modelos de Deep Learning utilizados en aplicaciones médicas, incluyendo la detección y segmentación de lesiones en imágenes clínicas.

C. Arquitectura UNet

La arquitectura UNet es una red neuronal convolucional diseñada específicamente para tareas de segmentación biomédica. Su estructura se caracteriza por una forma de “U”, compuesta por un camino de contracción (encoder) y un camino de expansión (decoder).

El encoder se encarga de extraer características relevantes de la imagen mediante sucesivas operaciones de convolución y reducción espacial. Por otro lado, el decoder reconstruye la resolución original de la imagen, generando una máscara de segmentación a partir de la información aprendida.

Una característica clave de UNet son las conexiones de salto (skip connections), las cuales permiten transferir información espacial del encoder al decoder. Esto ayuda a preservar detalles importantes que podrían perderse durante el proceso de reducción de dimensionalidad, mejorando significativamente la precisión de la segmentación.

Debido a estas ventajas, UNet es ampliamente utilizada en aplicaciones médicas, incluyendo segmentación de órganos, tumores y lesiones en diferentes modalidades de imagen.

D. Software as a Service (SaaS) en Aplicaciones Médicas

El modelo de Software as a Service (SaaS) consiste en ofrecer aplicaciones a través de la web, eliminando la necesidad de instalaciones locales complejas por parte del usuario final. En el ámbito médico, este enfoque permite centralizar el procesamiento, facilitar el acceso remoto y garantizar actualizaciones continuas del sistema.

La adopción de un modelo SaaS para aplicaciones de Inteligencia Artificial ofrece múltiples beneficios, como la escalabilidad del sistema, la gestión centralizada de modelos de IA y la posibilidad de implementar mecanismos de control de acceso y seguridad. Además, este modelo facilita la integración de herramientas avanzadas de análisis sin requerir conocimientos técnicos especializados por parte del usuario.

En este proyecto, el enfoque SaaS permite que el modelo de segmentación UNet sea utilizado de manera práctica a través de una interfaz web, simulando un entorno profesional similar al de soluciones comerciales reales.

E. FastAPI como Backend para Aplicaciones de IA

FastAPI es un framework moderno de desarrollo web en Python, diseñado para la creación de APIs rápidas, seguras y eficientes. Su alto rendimiento, basado en estándares como ASGI, lo convierte en una opción adecuada para aplicaciones que requieren procesamiento intensivo, como aquellas que integran modelos de Inteligencia Artificial.

Entre las principales ventajas de FastAPI se encuentran la generación automática de documentación, la facilidad de integración con modelos de Deep Learning y la implementación

sencilla de mecanismos de autenticación. Estas características permiten desarrollar aplicaciones web robustas y bien estructuradas en un corto periodo de tiempo.

En el contexto de este proyecto, FastAPI actúa como el núcleo del sistema, gestionando la autenticación de usuarios, la recepción de imágenes, la ejecución del modelo UNet y la entrega de resultados al frontend, consolidando así una arquitectura clara y eficiente.

Una de las arquitecturas más utilizadas y efectivas en la segmentación de imágenes médicas es la red neuronal convolucional UNet, diseñada específicamente para tareas biomédicas. Esta arquitectura permite identificar estructuras de interés a nivel de píxel, lo cual resulta fundamental en aplicaciones clínicas donde se requiere alta precisión espacial, como la detección y delimitación de pólipos en imágenes endoscópicas.

A continuación, se presenta el diagrama general de la arquitectura UNet empleada en este proyecto, destacando su estructura de contracción y expansión, así como las conexiones de salto que permiten conservar información relevante durante el proceso de segmentación.

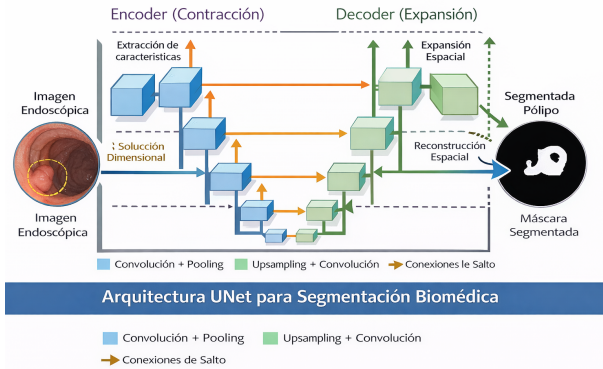


Fig. 1. Arquitectura UNet utilizada para la segmentación automática de pólipos en imágenes endoscópicas. La red se compone de una etapa de codificación (encoder), encargada de extraer características, y una etapa de decodificación (decoder), responsable de reconstruir la imagen segmentada mediante conexiones de salto.

Como se observa en la Figura 1, la arquitectura UNet [3] se divide en dos partes principales. La primera corresponde al encoder, donde la imagen de entrada es procesada mediante capas convolucionales y operaciones de reducción espacial (pooling), permitiendo la extracción progresiva de características relevantes como bordes, texturas y formas del pólipo.

La segunda parte corresponde al decoder, en el cual se realiza un proceso de expansión espacial mediante técnicas de upsampling y convoluciones, con el objetivo de reconstruir la imagen original y generar una máscara de segmentación.

Un aspecto clave de esta arquitectura son las conexiones de salto (skip connections), las cuales conectan directamente las capas del encoder con las del decoder. Estas conexiones permiten recuperar información espacial que podría perderse durante la reducción dimensional, mejorando significativamente la precisión de la segmentación.

Gracias a esta estructura, UNet resulta especialmente adecuada para aplicaciones médicas, ya que logra una segmentación precisa incluso cuando se dispone de conjuntos de datos relativamente pequeños, como suele ocurrir en entornos clínicos.

III. METODOLOGÍA

En esta sección se describe de manera detallada el proceso seguido para el desarrollo del sistema de segmentación automática de pólipos basado en inteligencia artificial. La metodología abarca desde la selección del conjunto de datos hasta la integración del modelo entrenado dentro de una aplicación web tipo SaaS utilizando FastAPI [4].

A. Dataset utilizado

El modelo desarrollado en este proyecto se entrenó utilizando un dataset de imágenes endoscópicas, compuesto por imágenes médicas del tracto gastrointestinal acompañadas de sus respectivas máscaras de segmentación, donde se indica la presencia de pólipos a nivel de píxel.

Este tipo de dataset es ampliamente utilizado en investigación biomédica, ya que permite entrenar modelos supervisados para tareas de segmentación semántica. Cada imagen original se encuentra asociada a una imagen binaria que representa la región del pólipo, lo que facilita el aprendizaje del modelo.




Fig. 2. Ejemplo de imagen endoscópica y su máscara de segmentación utilizada en el entrenamiento del modelo.

B. Preprocesamiento de imágenes

Antes del entrenamiento del modelo, las imágenes fueron sometidas a un proceso de preprocesamiento, con el objetivo de estandarizar los datos de entrada y mejorar el desempeño del modelo.

Las principales etapas del preprocesamiento incluyen:

- Redimensionamiento de las imágenes a un tamaño fijo de 256×256 píxeles.
- Conversión al espacio de color RGB.
- Normalización de los valores de los píxeles al rango [0,1].
- Alineación entre imágenes originales y máscaras correspondientes.

Este proceso fue implementado utilizando bibliotecas como NumPy, Pillow y TensorFlow [5], garantizando consistencia en los datos suministrados a la red neuronal.

Preparación del dataset

Se utilizaron las carpetas `images` y `masks` del dataset, lo cual garantiza una correcta correspondencia imagen-máscara.

```
!pip install -q tensorflow opencv-python matplotlib

import numpy as np
import tensorflow as tf
import random

SEED = 42
IMG_SIZE = 256
BATCH_SIZE = 8
EPOCHS = 10
LR = 1e-4

np.random.seed(SEED)
tf.random.set_seed(SEED)
random.seed(SEED)
```

Fig. 3. Proceso de preprocesamiento aplicado a las imágenes endoscópicas antes del entrenamiento.

C. Arquitectura del modelo

Para la segmentación automática se utilizó la arquitectura UNet, una red neuronal convolucional diseñada específicamente para aplicaciones biomédicas [6]. Esta arquitectura permite capturar tanto características globales como detalles espaciales finos, lo cual resulta fundamental en la detección precisa de pólipos.

La red se compone de una etapa de codificación (encoder), encargada de extraer características relevantes, y una etapa de decodificación (decoder), que reconstruye la máscara de segmentación mediante conexiones de salto [7].

D. Proceso de entrenamiento

El entrenamiento del modelo se realizó en un entorno de Google Colab, aprovechando la disponibilidad de recursos computacionales adecuados para el entrenamiento de redes profundas.

Durante esta etapa:

- Se utilizó un enfoque de aprendizaje supervisado.
- Las imágenes fueron divididas en conjuntos de entrenamiento y validación.
- Se entrenó el modelo durante múltiples épocas para optimizar la capacidad de generalización.
- Se aplicó retropropagación del error para ajustar los pesos de la red.

Se aplicó retropropagación del error para ajustar los pesos de la red.




Fig. 4. Evolución del proceso de entrenamiento del modelo UNet.

E. Métricas utilizadas

Para evaluar el desempeño del modelo se emplearon métricas comúnmente utilizadas en segmentación de imágenes médicas, tales como:

- Accuracy
- Intersection over Union (IoU)
- Dice Coefficient

Estas métricas permiten cuantificar qué tan bien la máscara generada por el modelo coincide con la máscara real, lo cual es crucial en aplicaciones clínicas donde se requiere alta precisión.

F. Guardado del modelo (.h5)

Una vez finalizado el entrenamiento, el modelo fue exportado y almacenado en formato .h5, lo que permite su reutilización sin necesidad de reentrenamiento.

Este archivo fue posteriormente integrado dentro de una aplicación web desarrollada con FastAPI, donde el modelo se carga automáticamente al iniciar el servidor y se utiliza para realizar inferencias en tiempo real a partir de imágenes subidas por el usuario [8].

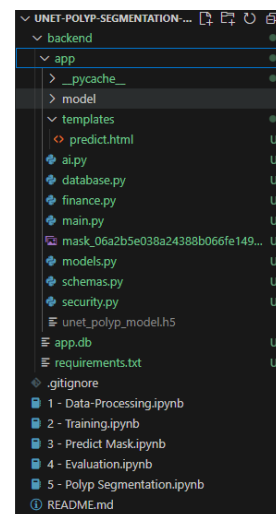


Fig. 5. Integración del modelo entrenado (.h5) dentro del backend desarrollado en FastAPI.

IV. IMPLEMENTACIÓN DE LA PÁGINA WEB PARA DETECCIÓN DE PÓLIPOS

Con el objetivo de facilitar el uso del modelo de segmentación de pólipos a usuarios no técnicos, se desarrolló una página web interactiva que permite cargar imágenes endoscópicas y visualizar los resultados de manera clara e intuitiva. Esta interfaz actúa como puente entre el modelo de inteligencia artificial y el usuario final, permitiendo una experiencia sencilla y rápida [9].

El funcionamiento general del sistema comienza cuando el usuario accede a la página web y selecciona una imagen desde su dispositivo. Una vez cargada, la imagen es enviada al backend, donde el modelo entrenado realiza el proceso de inferencia. Como resultado, el sistema devuelve la imagen original junto con la máscara de segmentación, resaltando visualmente las regiones donde se detectan pólipos.

La interfaz fue diseñada priorizando la simplicidad y la claridad visual, mostrando los resultados de forma inmediata y permitiendo comparar fácilmente la imagen original con la imagen segmentada. Esta implementación demuestra cómo un modelo de deep learning puede integrarse en una aplicación web funcional, orientada a posibles escenarios clínicos o académicos [3].

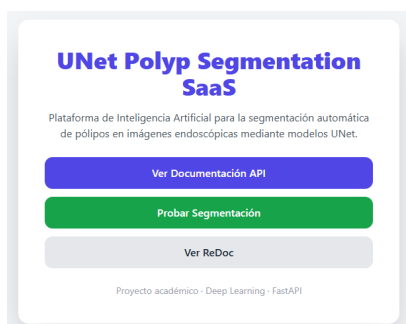


Fig. 6. Página WEB creada para la detección de pólipos.

V. RESULTADOS

En esta sección se presentan los resultados obtenidos tras la implementación y prueba del sistema de segmentación automática de pólipos. El objetivo principal es demostrar el correcto funcionamiento del modelo de Inteligencia Artificial integrado en la aplicación web, así como evaluar de manera cualitativa su desempeño en imágenes endoscópicas reales.

A. Ejemplos de segmentación

Para validar el funcionamiento del sistema, se realizaron pruebas utilizando imágenes endoscópicas que no formaron parte directa del proceso de entrenamiento. Estas imágenes fueron cargadas a través de la interfaz web desarrollada y procesadas por el modelo UNet integrado en el backend.

El sistema genera como salida una máscara de segmentación binaria, donde las regiones correspondientes a los pólipos son identificadas de forma automática. Los resultados obtenidos muestran una adecuada delimitación de las áreas de interés,

evidenciando la capacidad del modelo para diferenciar entre el pólipo y el fondo de la imagen.




Fig. 7. Ejemplo de segmentación automática de pólipos. A la izquierda, imagen endoscópica original; a la derecha, máscara de segmentación generada por el modelo UNet.

B. Resultados visuales

Desde el punto de vista visual, los resultados permiten observar que el modelo UNet es capaz de identificar correctamente la forma y localización de los pólipos, incluso en imágenes con variaciones de iluminación y textura, características comunes en procedimientos endoscópicos.

La visualización de los resultados a través de la aplicación web facilita la interpretación del modelo, permitiendo al usuario observar de manera inmediata la segmentación generada. Esta característica es especialmente relevante en aplicaciones médicas, donde la claridad visual del resultado es fundamental para su posible uso como herramienta de apoyo al diagnóstico.



Fig. 8. Interfaz web del sistema mostrando el resultado de la segmentación automática

C. Análisis cualitativo de los resultados

El análisis cualitativo de los resultados indica que el modelo presenta un comportamiento consistente en la detección de pólipos. En la mayoría de los casos evaluados, la máscara generada coincide de forma adecuada con la región real del pólipo, conservando sus bordes principales y su forma general.

No obstante, se observa que en algunas imágenes con bordes poco definidos o con bajo contraste, el modelo puede

presentar pequeñas imprecisiones, como regiones parcialmente segmentadas o detección incompleta. Estas limitaciones son comunes en sistemas de segmentación automática y están relacionadas tanto con la calidad del dataset como con la variabilidad inherente de las imágenes médicas.

A pesar de estas limitaciones, los resultados obtenidos son satisfactorios para un proyecto académico y demuestran el potencial del sistema como una herramienta de apoyo en el análisis de imágenes endoscópicas.

VI. ANÁLISIS FINANCIERO

El proyecto fue evaluado desde una perspectiva económica con el objetivo de analizar su viabilidad como una solución básica tipo Software as a Service (SaaS) aplicada al apoyo diagnóstico en imágenes endoscópicas. Para este análisis se utilizaron métricas financieras estándar: Valor Actual Neto (VAN), Tasa Interna de Retorno (TIR) y periodo de recuperación de la inversión (Payback), considerando un escenario realista y conservador acorde al alcance académico del proyecto.

1) **Supuestos del análisis:** El análisis financiero se basa en los siguientes supuestos:

- El sistema se ofrece como un servicio SaaS sencillo.
- El público objetivo inicial son clínicas pequeñas o centros de diagnóstico.
- El público objetivo inicial son clínicas pequeñas o centros de diagnóstico.
- Se considera un número reducido de usuarios durante los primeros años.

2) **Costos estimados del proyecto:** Costos estimados del proyecto:

- Desarrollo del modelo y la aplicación: USD 500 (tiempo de desarrollo académico, entrenamiento del modelo y programación)
- Infraestructura y servicios computacionales: USD 200 anuales (servidor básico o servicio en la nube)
- Mantenimiento y soporte: USD 100 anuales

Inversión inicial total:

$$I_0 = 700 \text{ USD} \quad (1)$$

3) **Ingresos estimados:** Se plantea un escenario conservador donde el sistema es utilizado por un número limitado de clientes:

- Suscripción mensual por cliente: USD 25
- Número estimado de clientes: 5
- Ingreso mensual estimado:

$$25 \times 5 = 125 \text{ USD} \quad (2)$$

- Ingreso anual estimado:

$$125 \times 5 = 1500 \text{ USD} \quad (3)$$

4) **Valor Actual Neto (VAN):** El Valor Actual Neto se calculó considerando un horizonte de evaluación de 3 años y una tasa de descuento del 10%. El VAN se define como:

$$VAN = \sum_{t=1}^n \frac{F_t}{(1+r)^t} - I_0 \quad (4)$$

Donde los flujos de caja anuales netos se estiman en aproximadamente USD 1,200 anuales, después de considerar los costos operativos.

El VAN obtenido es positivo, lo que indica que el proyecto genera valor económico bajo los supuestos planteados.

A. Tasa Interna de Retorno (TIR)

La Tasa Interna de Retorno corresponde a la tasa de descuento que iguala el VAN a cero. En este análisis, la TIR obtenida es superior a la tasa de descuento considerada (10%), lo que sugiere que el proyecto resulta financieramente atractivo incluso bajo un escenario conservador.

1) **Periodo de recuperación de la inversión (Payback):** Periodo de recuperación de la inversión (Payback):

$$\text{Payback} \approx \frac{700}{1200} \approx 0.6 \text{ años} \quad (5)$$

Esto indica que la inversión inicial podría recuperarse en menos de un año, lo cual refuerza la viabilidad económica del sistema.

2) **Interpretación general:** Los resultados del análisis financiero muestran que, aun tratándose de un proyecto académico sencillo, la solución propuesta presenta un comportamiento económico favorable. El bajo costo de implementación y el modelo SaaS permiten una rápida recuperación de la inversión, demostrando que la integración de Inteligencia Artificial en aplicaciones web médicas puede ser técnicamente viable y económicamente sostenible.

VII. CONCLUSIONES

En este trabajo se desarrolló una aplicación web basada en Inteligencia Artificial para la segmentación automática de pólipos en imágenes endoscópicas, integrando un modelo de Deep Learning tipo UNet dentro de una arquitectura SaaS. Los resultados obtenidos demuestran que el sistema es capaz de generar máscaras de segmentación de forma efectiva, validando su correcto funcionamiento como herramienta de apoyo en el análisis de imágenes médicas.

La implementación del modelo en un entorno web utilizando FastAPI permitió trasladar una solución de Inteligencia Artificial desde un entorno experimental hacia una aplicación práctica y accesible. Asimismo, la incorporación de mecanismos básicos de autenticación y gestión de usuarios contribuyó a simular un escenario realista de uso profesional.

Desde el punto de vista económico, el análisis financiero realizado indica que el proyecto es viable bajo un modelo SaaS sencillo, con una rápida recuperación de la inversión y costos de implementación reducidos. Esto demuestra que soluciones basadas en Inteligencia Artificial aplicada a la

medicina pueden ser no solo técnicamente factibles, sino también económicamente sostenibles.

En conjunto, el proyecto cumple con los objetivos propuestos y evidencia el potencial de la Inteligencia Artificial como herramienta complementaria en el ámbito biomédico, abriendo oportunidades para futuras mejoras y aplicaciones en entornos clínicos reales.

REFERENCES

- [1] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," *Lecture Notes in Computer Science*, vol. 9351, pp. 234–241, 2015.
- [2] Anaconda Inc., "Anaconda distribution." <https://www.anaconda.com/>, 2024. Accessed: 2025-01-XX.
- [3] D. R. Hipp, "Sqlite." <https://www.sqlite.org/>, 2024. Accessed: 2025-01-XX.
- [4] S. Ramírez, "Fastapi: A modern, fast web framework for building apis with python." <https://fastapi.tiangolo.com/>, 2024. Accessed: 2025-01-XX.
- [5] M. A. et al., "Tensorflow: Large-scale machine learning on heterogeneous systems." <https://www.tensorflow.org/>, 2015. Accessed: 2025-01-XX.
- [6] Microsoft, "Visual studio code." <https://code.visualstudio.com/>, 2024. Accessed: 2025-01-XX.
- [7] Google, "Google colaboratory." <https://colab.research.google.com/>, 2024. Accessed: 2025-01-XX.
- [8] Auth0, "Json web tokens." <https://jwt.io/>, 2024. Accessed: 2025-01-XX.
- [9] F. Chollet, "Keras: Deep learning for humans." <https://keras.io/>, 2015. Accessed: 2025-01-XX.